

Deploy no Cloud Run — Guia para o Grupo de MLOps

Objetivo: Implantar os microsserviços `search-svc` e `report-svc` no Google Cloud Run e acompanhar os logs via console do GCP durante a apresentação.

Pré-requisitos

Antes de começar, verifique se as ferramentas estão instaladas:

```
gcloud --version # Google Cloud SDK
docker --version # Docker (usado no build via Cloud Build)
make --version   # Make (para os atalhos do Makefile)
```

1. Configuração Inicial do GCP

1.1 Login e seleção do projeto

```
# Autenticar no Google Cloud
gcloud auth login

# Configurar o projeto (substitua pelo seu Project ID)
gcloud config set project SEU_PROJECT_ID

# Confirmar projeto ativo
gcloud config get-value project
```

1.2 Habilitar as APIs necessárias

```
gcloud services enable \
  run.googleapis.com \
  cloudbuild.googleapis.com \
  artifactregistry.googleapis.com
```

2. Estrutura dos Microsserviços

```
microservices/  
├── search-svc/    ← API de busca semântica  
└── report-svc/    ← API de geração de relatórios
```

Cada microsserviço expõe dois endpoints principais: - `GET /health` — verifica se o serviço está operante. - `POST /search` ou `POST /generate` — funcionalidades principais.

3. Deploy

3.1 Deploy de todos os microsserviços (recomendado)

```
make deploy
```

O script realiza o deploy de ambos os serviços no Cloud Run e exibe as URLs finais.

3.2 Deploy individual

```
# Apenas o search-svc  
make deploy-search  
  
# Apenas o report-svc  
make deploy-report
```

4. Verificar URLs e Status

Após o deploy, veja as URLs dos serviços:

```
make urls
```

Para verificar se os serviços estão respondendo corretamente:

```
make health
```

5. Visualizar Logs (GCP Console)

Para acompanhar o que acontece nos microsserviços em tempo real, utilize a interface do Google Cloud Console. Isso permite visualizar erros e o fluxo de dados sem depender de componentes locais do gcloud.

Passo a passo:

1. Acesse o [Console do Google Cloud](#).
2. No menu lateral, navegue até **Cloud Run**.
3. Clique no nome do serviço desejado (`search-svc` ou `report-svc`).
4. Clique na aba **Logs**.
5. (Opcional) Utilize o filtro de "Severidade" para isolar erros ou o campo de busca para filtrar requisições específicas.

6. Configuração do Orquestrador e Frontend

Após o deploy, você deve configurar o Orquestrador para apontar para os serviços no Cloud Run.

1. **Atualize o `.env`**: Copie as URLs geradas pelo `make urls` para o arquivo `.env` na raiz do projeto.
2. **Inicie os serviços em modo "produção"**: Utilize o Makefile para rodar o orquestrador e o dashboard em segundo plano, já conectados aos serviços live no GCP:

```
make up-prod
```

Este comando utiliza o `docker-compose.prod.yml` para subir apenas o que é necessário localmente.

7. Roteiro para a Apresentação

Terminal 1 — Orquestrador e Frontend (Background):

```
make up-prod
```

Navegador — Logs e Interface: 1. Abra o Console do GCP na aba de Logs do `search-svc`. 2. Abra o Dashboard (geralmente em `http://localhost:3000`). 3. Dispare uma pergunta e mostre os logs aparecendo no navegador.

O que mostrar ao grupo

1. **Arquitetura Desacoplada:** Explique que o Orquestrador está local (ou em outro container) enquanto os motores de Busca e Relatório estão escalando de forma independente no Cloud Run.
2. **Observabilidade:** Mostre como o Cloud Run facilita a visualização de logs e métricas via interface web.
3. **Escalabilidade:** Comente que o Cloud Run escala para zero quando não há requisições, economizando custos.

8. Comandos de Referência Rápida

Comando	O que faz
<code>make deploy</code>	Deploy de todos os microsserviços
<code>make up-prod</code>	Inicia Orquestrador + Frontend (conectados ao GCP)
<code>make down-prod</code>	Para os serviços de produção
<code>make urls</code>	Exibe as URLs no Cloud Run
<code>make health</code>	Verifica os health checks
<code>make up</code>	Inicia todo o stack localmente (Dev)

9. Troubleshooting

❌ Cold start lento na primeira requisição

Comportamento esperado em serviços com `--min-instances 0`. A primeira requisição pode levar alguns segundos para inicializar.